Hello, my name is INFLUENCER

Data Science lab

a.a. 2017/2018

Alex Ceccotti | 790497

Michela Sessi | 777760

Stefano Fiorini | 778379

David Govi | 833653



Predire il giudizio umano su chi è ritenuto più **influente** tra due **utenti Twitter**

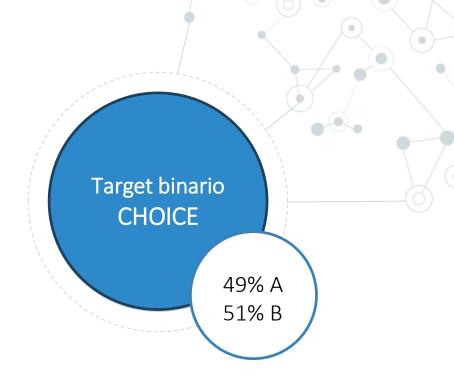


Riconoscere gli Influencer automaticamente

Dataset

Per ogni utente:

- Following_count
- Follower_count
- Retweets_received
- Retweets_sent
- Mentions_received
- Mentions_sent
- Posts
- Listed_count
- Network_feature_1
- Network_feature_2
- Network_feature_3





Data manipulation



Creazione dei **rapporti** tra le variabili di A e B





Se il rapporto = **Inf** tengo A Se il rapporto è NA metto 1

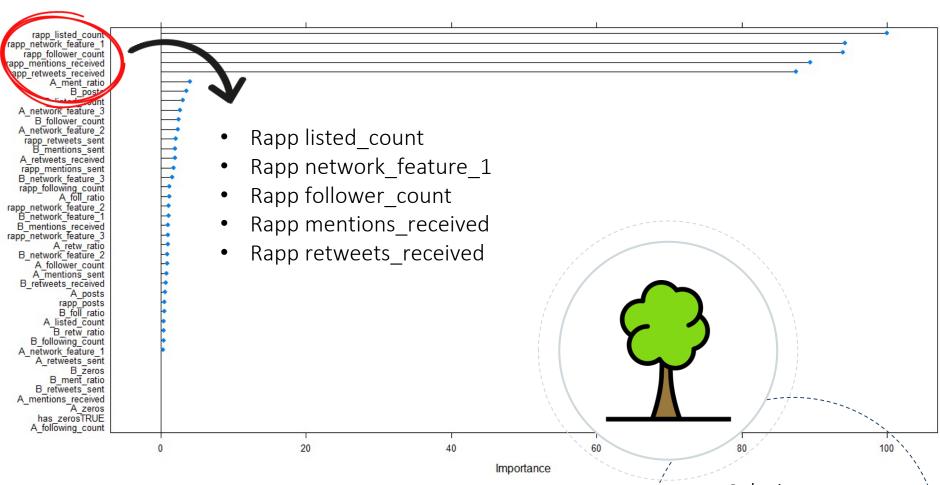
Creazione di ratio interni all'utente: Folfol, Menmen, Retret





Dataset 5500 rows 42 variabili

Conteggio degli **zeri** per utente e **variabile HasZero**



Feature selection

Albero cross-validato 10folds Tuning con ROC = 0.8266 Selezione per:
Neural Networks
Support Vector Machine
K Nearest Neighbors
Logistica

Modelli testati



1. Random Forest

2. Naive Bayes

3. XGBoost

4. Stochastic Gradient Boosting

5. Neural Networks

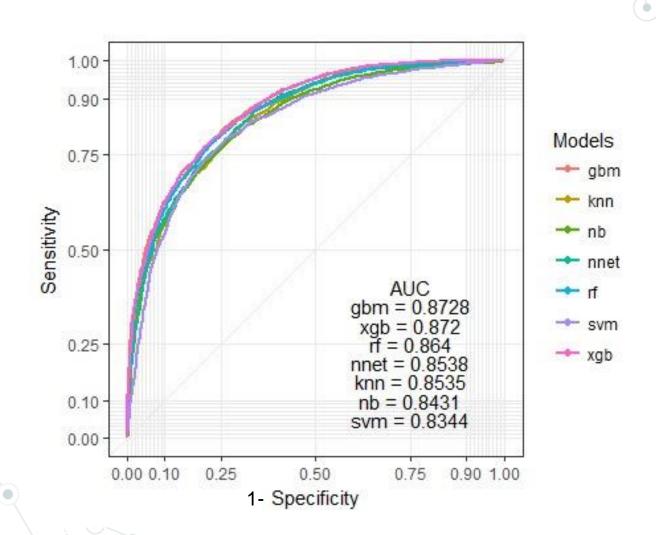
6. K Nearest Neighbors

7. Support Vector Machine

8. Regressione logistica

Per tunare e scegliere il modello migliore è stata utilizzata la ROC

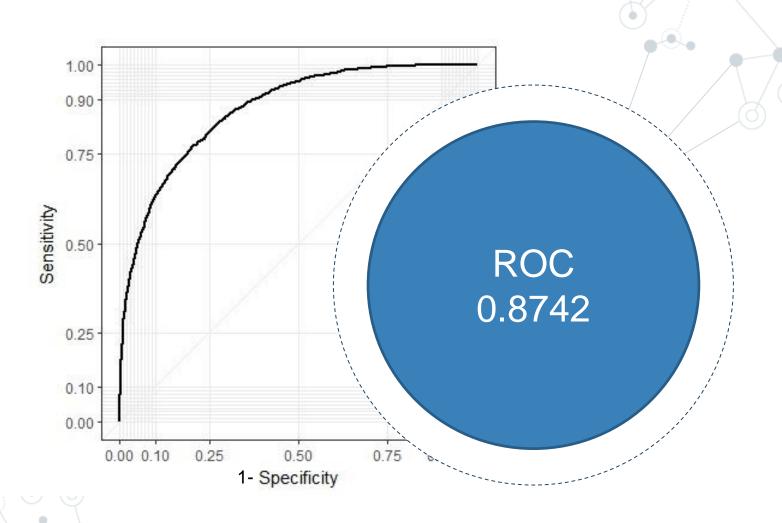
ROC curves



Ensamble method Random **XGBoost** Forest 20% 30% Stochastic Gradient Boosting

50%

Best model















Prob. = 0.08









Prob. = 0.55



Prob. = 0.45





Grazie per l'attenzione

Data Science lab a.a. 2017/2018

Alex Ceccotti | 790497

Michela Sessi | 777760

Stefano Fiorini | 778379

David Govi | 833653